

Ollama Quickstart Guide: Getting Started with Large Language Models Locally

Sumber: <https://docs.ollama.com/quickstart>

Tanggal akses: 12 Mei 2026

Pendahuluan

Ollama adalah platform open-source yang menyederhanakan proses menjalankan large language models (LLMs) secara lokal pada perangkat pengguna. Ollama membungkus kompleksitas inference engine (llama.cpp) ke dalam antarmuka CLI dan REST API yang intuitif, memungkinkan peneliti dan pengembang untuk menggunakan LLMs tanpa memerlukan infrastruktur cloud atau GPU kelas server. Ollama tersedia untuk sistem operasi macOS, Windows, dan Linux, serta mendukung berbagai arsitektur hardware termasuk GPU NVIDIA (CUDA), AMD (ROCm), Apple Silicon (Metal), dan GPU Intel (Vulkan).

Persyaratan Sistem

Model	RAM Minimal	Penyimpanan	GPU yang Didukung
Llama 3.2 1B / Gemma 3 1B	4 GB	~1 GB	CPU, iGPU, Semua GPU
Llama 3.2 3B / Phi-4	8 GB	~2.5 GB	CPU, iGPU, Semua GPU
Llama 3.1 8B / Mistral	16 GB	~5 GB	NVIDIA, AMD, Apple Silicon
Llama 3.1 70B	48 GB	~40 GB	NVIDIA A100/H100, multi-GPU
Llama 3.1 405B	256 GB	~230 GB	Cluster multi-GPU

Instalasi

macOS

```
curl -fsSL https://ollama.com/install.sh | sh
```

Atau unduh installer manual dari ollama.com/download. Mendukung Apple Silicon (M-series) dan Intel Mac.

Windows

```
irm https://ollama.com/install.ps1 | iex
```

Ollama untuk Windows menyediakan installer GUI. Mendukung akselerasi GPU NVIDIA (CUDA) dan GPU AMD (ROCm).

Linux

```
curl -fsSL https://ollama.com/install.sh | sh
```

Mendukung distribusi Linux berbasis apt (Ubuntu/Debian) dan yum/dnf (RHEL/Fedora). Akselerasi GPU tersedia untuk NVIDIA (CUDA), AMD (ROCm), dan Intel (Vulkan/SYCL).

Docker

```
docker pull ollama/ollama
# Dengan GPU NVIDIA
docker run --gpus all -d -v ollama:/root/.ollama -p 11434:11434 --name ollama
ollama/ollama
# Dengan GPU AMD
docker run --device /dev/kfd --device /dev/dri -d -v ollama:/root/.ollama -p
11434:11434 --name ollama ollama/ollama
```

Manajemen Model

Mengunduh Model (Pull)

```
# Pull model default (tag :latest)
ollama pull llama3.2

# Pull model dengan tag spesifik
ollama pull gemma3:12b
ollama pull mixtral:8x7b

# Melihat model yang tersedia
ollama list
```

```
# Melihat model yang sedang berjalan
ollama ps
```

Menjalankan Model

```
# Mode interaktif (chat)
ollama run llama3.2

# One-shot prompt
ollama run llama3.2 "Jelaskan konsep transfer learning dalam NLP"

# Dengan parameter kustom
ollama run llama3.2 --temperature 0.3 --num-ctx 4096
```

Berhenti dan Hapus Model

```
# Hentikan model yang sedang berjalan
ollama stop llama3.2

# Hapus model dari penyimpanan lokal
ollama rm llama3.2
```

Modelfile — Kustomisasi Model

Modelfile adalah blueprint untuk membuat dan menyesuaikan model di Ollama. Formatnya mirip Dockerfile dan memungkinkan pengguna mengatur parameter inference, prompt template, system message, dan LoRA adapters.

```
# Contoh Modelfile untuk asisten Mario
FROM llama3.2
PARAMETER temperature 0.7
PARAMETER num_ctx 4096
PARAMETER top_p 0.9
SYSTEM Anda adalah Mario dari Super Mario Bros, membantu pengguna dengan ramah.
TEMPLATE ""{{ if .System }}<|im_start|>system
{{ .System }}<|im_end|>
{{ end }}{{ if .Prompt }}<|im_start|>user
{{ .Prompt }}<|im_end|>
```

```
{{ end }}<|im_start|>assistant  
"""
```

```
# Membuat dan menjalankan model kustom  
ollama create mario-assistant -f ./Modelfile  
ollama run mario-assistant
```

Parameter Modelfile

Parameter	Deskripsi	Default
temperature	Mengontrol kreativitas output. Nilai tinggi (>1) = lebih kreatif, rendah (<0.5) = lebih fokus.	0.8
num_ctx	Ukuran context window dalam token. Mempengaruhi panjang konteks yang dapat diingat model.	2048
top_k	Membatasi jumlah token yang dipertimbangkan pada setiap langkah. Nilai tinggi = lebih beragam.	40
top_p	Nucleus sampling — akumulasi probabilitas token yang dipertimbangkan.	0.9
min_p	Probabilitas minimum relatif terhadap token paling mungkin. Alternatif top_p yang lebih stabil.	0.0
repeat_penalty	Penalti pengulangan token. Nilai >1 mengurangi repetisi.	1.1
seed	Random seed untuk reproducibility. Seed yang sama = output yang sama.	0
num_predict	Maksimum token yang akan digenerate. -1 = tidak terbatas.	-1
stop	Sequence penghenti. Model berhenti generate saat pattern ini ditemukan.	-

REST API

Ollama menyediakan REST API pada `http://localhost:11434/api` (dapat diubah melalui environment variable `OLLAMA_HOST`).

Endpoint Chat

```
curl http://localhost:11434/api/chat -d '{  
  "model": "gemma3",  
  "messages": [  
    {"role": "system", "content": "Anda adalah asisten yang membantu."},  
    {"role": "user", "content": "Apa itu transfer learning?"}  
  ],  
  "stream": false,  
  "options": {  
    "temperature": 0.3,  
    "num_ctx": 8192  
  }  
'
```

```
}  
'
```

Endpoint Generate

```
curl http://localhost:11434/api/generate -d '{  
  "model": "gemma3",  
  "prompt": "Jelaskan arsitektur transformer dalam 3 paragraf.",  
  "stream": false  
'
```

Endpoint Embeddings

```
curl http://localhost:11434/api/embed -d '{  
  "model": "nomic-embed-text",  
  "input": "Teks yang akan diubah menjadi vektor embedding"  
'
```

Endpoint Lainnya

- **GET /api/tags** — Daftar model yang tersedia
- **POST /api/pull** — Mengunduh model dari registry
- **POST /api/push** — Mengunggah model ke registry
- **POST /api/create** — Membuat model dari Modelfile
- **DELETE /api/delete** — Menghapus model
- **POST /api/copy** — Menyalin model
- **POST /api/show** — Informasi detail model (Modelfile)
- **GET /api/ps** — Model yang sedang berjalan

Akselerasi GPU

Backend	Platform	Variable Lingkungan
CUDA	NVIDIA GPU (Linux, Windows)	OLLAMA_CUDA=1 (default jika NVIDIA driver terdeteksi)
ROCm	AMD GPU (Linux)	OLLAMA_ROCM=1
Metal	Apple Silicon (macOS)	Default untuk M1/M2/M3/M4
Vulkan	GPU Intel/AMD (Linux)	OLLAMA_VULKAN=1

SYCL	GPU Intel (Linux)	OLLAMA_SYCL=1
------	-------------------	---------------

Konfigurasi Lingkungan

Variable	Fungsi	Default
OLLAMA_HOST	Alamat binding server	127.0.0.1:11434
OLLAMA_MODELS	Direktori penyimpanan model	~/.ollama/models
OLLAMA_NUM_PARALLEL	Jumlah request paralel	1
OLLAMA_MAX_LOADED_MODELS	Maksimum model yang dimuat bersamaan	1
OLLAMA_KEEP_ALIVE	Durasi model bertahan di memori setelah request terakhir	5m
OLLAMA_DEBUG	Mode debug dengan log detail	0
OLLAMA_FLASH_ATTENTION	Mengaktifkan flash attention untuk efisiensi memori	0

Integrasi dengan Framework AI

Ollama dapat digunakan sebagai backend LLM dalam berbagai framework AI populer:

- **LangChain (Python/JS):** `from langchain_ollama import ChatOllama`
- **LlamaIndex:** `from llama_index.llms.ollama import Ollama`
- **Haystack:** Integrasi melalui komponen `OllamaGenerator`
- **Spring AI:** Konfigurasi melalui `spring.ai.ollama.base-url`
- **Semantic Kernel (Microsoft):** Connector Ollama tersedia dalam Python SDK

Pertimbangan Penggunaan untuk Tesis

Ollama relevan untuk penelitian yang membutuhkan:

1. **Reproducibility:** Dengan mengatur `seed` dan `temperature=0`, output model dapat direproduksi.
2. **Privasi Data:** Semua inferensi terjadi secara lokal — data tidak meninggalkan perangkat pengguna. Kritis untuk penelitian dengan data sensitif.
3. **Biaya:** Tidak memerlukan API berbayar atau langganan cloud. Cocok untuk penelitian skala kecil hingga menengah.
4. **Offline:** Dapat beroperasi penuh tanpa koneksi internet setelah model diunduh.

5. **Keterbatasan:** Bergantung pada kapasitas hardware lokal. Model besar (>13B parameter) memerlukan GPU dengan VRAM >16 GB untuk performa optimal.
-

Dokumen ini dicetak dari sumber online untuk keperluan referensi tesis.

Sumber asli: <https://docs.ollama.com/quickstart> — Diakses pada 12 Mei 2026.