

Strategi Segmentasi Probabilistik Calon Mahasiswa Menggunakan Gaussian Mixture Model dan Otomasi Analisis Large Language Model untuk Optimalisasi Rekrutmen di ITSNU Pekalongan

Integrasi IndoBERT, Gaussian Mixture Model, dan Hybrid Cognitive Pipeline (LLM Lokal + Cloud) untuk Segmentasi Adaptif Berbasis Time Series 2019–2024

Mujibul Hakim · NIM 25.01.85.7010 · Magister Teknologi Informasi

Pembimbing: Dr. Drs. Eri Zuliarso, M.Kom., MCF · Fakultas Teknologi Informasi dan Industri, Universitas Stikubank (UNISBANK) Semarang

LATAR BELAKANG

Rekrutmen Reaktif di Tengah Volatilitas

- Pendaftar ITSNU Pekalongan berfluktuasi tajam: 146 (2019) → 680 puncak (2023) → koreksi 503 (2024).
- Strategi konvensional memperlakukan calon mahasiswa sebagai populasi homogen, mengabaikan pergeseran struktural antar periode.
- Data teks pendaftaran belum dimanfaatkan sebagai sinyal segmentasi semantik.


RUMUSAN MASALAH & TUJUAN

Tiga Pertanyaan Kunci

- Bagaimana pola segmentasi probabilistik dapat diidentifikasi konsisten dari data time series 2019–2024?
- Bagaimana stabilitas struktur segmen berubah antar fase pra-COVID, krisis, dan recovery?
- Bagaimana otomasi LLM menerjemahkan hasil kluster menjadi strategi rekrutmen aplikatif?

DATASET


2.362 Pendaftar, 6 Periode Akademik



Dominasi program berbasis IT: Sarjana Informatika (30,9%) & Sarjana Teknologi Informasi (28,2%) — 59,1% dari total pendaftar.

KERANGKA KONSEPTUAL

Hybrid Cognitive Pipeline



Model lokal (Ollama/Llama 3.2) memproses data mentah untuk menjaga privasi PII; hanya statistik kluster teragregasi dikirim ke model cloud (via proxy OpenRouter) untuk reasoning strategis.

METODOLOGI

CRISP-DM Adaptif Time Series




HASIL — K-SCAN GMM

K Optimal Bervariasi Antar Periode

Tahun	K	Silhouette	Fase
2019	2	0,0522	Pre COVID
2020	3	0,1066	COVID Crisis
2021	2	0,0748	COVID Crisis
2022	2	0,0663	Recovery
2023	5	0,1199	Recovery
2024	4	0,0669	Recovery

HASIL UTAMA

Segmentasi & Stabilitas



GMM unggul dari K-Means pada tiga kemampuan kunci: soft clustering (posterior probability), basis reasoning kausal LLM, dan dukungan proyeksi segmen 2025 — bukan sekadar metrik klasterisasi konvensional.

KESIMPULAN

Tiga Temuan Utama

- Integrasi IndoBERT + GMM efektif**
K=2 konsisten di seluruh 6 periode; posterior probability 0,514–1,000.
- Struktur segmen tidak stabil antar periode**
4 dari 5 transisi structural break — strategi rekrutmen perlu adaptif per periode.
- Hybrid Cognitive Pipeline terbukti aplikatif**
Rekomendasi channel selaras akurat dengan pola perilaku kluster GMM.

SARAN PENELITIAN LANJUTAN

Arah Pengembangan

- Eksplorasi Dirichlet Process Mixture Model (DPMM) untuk penentuan K otomatis secara inferensial.
- Fine-tuning Small Language Model (Llama-3-8B) on-premise guna mengurangi ketergantungan API cloud.

Segmentasi GMM IndoBERT LLM Rekrutmen